Inteligencia de Negocio, Curso 2023-2024
Grado en Ingeniería Informática, Universidad de Granada

Convocatoria Ordinaria, Examen de Teoría

17 de enero de 2024

Apellidos, Nombre:

.....

Tiempo disponible: *2,5 horas*

1. **(1,5 ptos.)** Justifica en qué orden aplicarías los siguientes métodos de procesado de datos: reducción del ruido, balanceo de clases por muestreo, selección de características e imputación de valores perdidos.

2. **(2 ptos.)** Compara justificadamente ventajas y desventajas de los siguientes algoritmos de *clustering*: K-Means, DBSCAN, Mean Shift, Jerárquico Aglomerativo Ward y BIRCH.

3. **(1,5 ptos.)** Explica qué inconvenientes puede presentar la *confianza* para valorar la fiabilidad de una regla de asociación y propón una alternativa que palíe esos inconvenientes.

4. **(2 ptos.)** Disponemos del siguiente conjunto de datos con cuatro variables numéricas:

id	x_1	x_2	x_3	x_4
1	40	2	1	0
2	50	3	2	3
3	50	4	2	2
4	65	4	1	3
5	50	1	2	1
6	40	1	2	0

Centroides iniciales

Cluster	x_1	x_2	x_3	x_4
A	50	2	2	1
B	40	2	2	2

Escoge la medida de distancia más apropiada y traza paso a paso el algoritmo K-Means para agrupar los datos en dos *clusters*, siendo sus centroides iniciales al comienzo del algoritmo los indicados arriba. Completa las tablas de la siguiente página con los resultados.

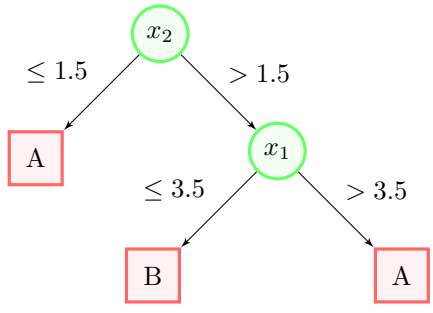
5. **(3 ptos.)** Dado el conjunto de datos de más abajo, escoge la medida de distancia más apropiada y aplica el algoritmo SMOTE con $k = 2$ para igualar la frecuencia de las dos clases. Escoge los números aleatorios que necesites en el orden de arriba a abajo que se indica en la tabla con la columna *random*.

   A continuación, dado el árbol de decisión de más abajo, compara los resultados de predicción con F_1-score sobre la clase 'A' entre el conjunto de datos original y añadiendo a ese conjunto los nuevos datos sintéticos creados. ¿Qué opción predice mejor y por qué?

   Completa las tablas de la siguiente página con los resultados.

id	x_1	x_2	x_3	x_4	***clase***
1	4	2	1	0	A
2	3	2	2	0	B
3	7	1	1	3	B
4	3	1	2	1	A
5	4	2	2	0	A
6	2	4	2	1	B
7	4	1	1	2	A
8	3	1	2	0	A
9	4	1	0	1	A
10	3	1	0	1	A
11	3	2	1	0	B
12	4	2	0	0	A

random
0.2
0.8
0.6
0.1
0.3
0.5
0.9
0.2
0.7
0.5
0.4
0.3
...



Ej. 4: Agrupamiento final

id	***Cluster***
1	
2	
3	
4	
5	
6	

Ejercicio 4: Centroides finales de los *clusters*

Cluster	x_1	x_2	x_3	x_4
A				
B				

Ejercicio 5: Datos sintéticos generados por SMOTE

x_1	x_2	x_3	x_4	***clase***

Ej. 5: Matriz de confusión sobre el conjunto original

Real \ **Predicho**	A	B
A		
B		

F_1-score (sobre clase 'A') =

Ej. 5: Matriz de confusión añadiendo datos sintéticos

Real \ **Predicho**	A	B
A		
B		

F_1-score (sobre clase 'A') =