Ejercicio 4. Dado que los atributos tienen rangos dispares, deberemos realizar alguna normalización para que la medida de distancia sea representativa. Podemos emplear esta medida: $d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{k=1}^{4} \left(\frac{x_{jk} - x_{ik}}{\max x_k - \min x_k} \right)^2}$.

Ej. 4: Agrupamiento final

id	***Cluster***
1	A
2	B
3	B
4	B
5	A
6	A

Ejercicio 4: Centroides finales de los *clusters*

Cluster	x_1	x_2	x_3	x_4
A	43.333	1.333	1.667	0.333
B	55.000	3.667	1.667	2.667

Ejercicio 5. Hay que añadir 4 datos de la clase B, así que se genera uno sintético a partir de cada uno de los 4 ejemplos de esa clase. Empleamos la misma medida de distancia del ejercicio 3. Con esta distancia, los dos ($k = 2$) vecinos del ejemplo id_2 son el id_6 y el id_{11}, los de id_3 son id_2 e id_{11}, los de id_6 son id_2 e id_{11}, y los de id_{11} son id_2 e id_6. Empezamos por el primer dato de la clase B (id_2), y como el primer número aleatorio es el 0.2 (< 0.5), se escoge el primero de los dos vecinos (id_6). Por lo que se genera un dato sintético entre el dato (3,2,2,0) y su vecino (2,4,2,1) empleando el siguiente número aleatorio (0.8). Pasamos ahora al segundo dato de la clase B, y entre sus dos vecinos, escogemos el segundo (o sea, id_{11}) porque ahora el número aleatorio es 0.6. Se genera un nuevo dato sintético entre el dato (7,1,1,3) y su vecino (3,2,1,0) empleando el número aleatorio 0.1. Igual se hace con el tercer y cuarto dato de la clase B hasta generar los cuatro datos de la siguiente tabla.

Ejercicio 5: Datos sintéticos generados por SMOTE

x_1	x_2	x_3	x_4	***clase***
2.2	3.6	2.0	0.8	B
6.6	1.1	1.0	2.7	B
2.5	3.0	2.0	0.5	B
2.8	2.4	1.2	0.2	B

Ej. 5: Matriz de confusión sobre el conjunto original

Real \ **Predicho**	A	B
A	8	0
B	1	3
F_1-score (sobre 'A') = 0.94118, prec. = 0.88889, recall = 1		

Ej. 5: Matriz de confusión añadiendo datos sintéticos

Real \ **Predicho**	A	B
A	8	0
B	2	6
F_1-score (sobre 'A') = 0.88889, prec. = 0.8, recall = 1		

De los cuatro ejemplos sintéticos generados, tres se clasifican acertadamente con la clase 'B', pero uno de ellos se clasifica erróneamente con la clase 'A'. Por tanto, F_1-score sobre la clase 'A' resulta peor si se añaden al cálculo los datos sintéticos. Sobre la clase 'B', precision es 1 y recall 0.75 en ambos casos. En definitiva, dado que el error en clasificar la clase 'B' es 0.25 antes y después de añadir los datos sintéticos, no se produce mejora en la predicción del árbol. No olvidemos que en un caso real, SMOTE se usa para generar datos y entrenar de nuevo el algoritmo, que generaría un nuevo árbol que previsiblemente podría predecir mejor nuevos casos.