Universidad de Granada
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL
ETSII Informática y de Telecomunicación, C/Periodista Daniel Saucedo Aranda s/n - 18071 - Granada (España)

.....

Recuperación de Información

Convocatoria ordinaria de 16 de enero de 2025

Parcial 1: Tiempo 1 hora 30 min

1. (2 puntos) Para cada una de la siguientes cuestiones identifica cuál o cuales de de las respuestas ofrecidas puede puede ser cierta y para cada una de ellas **justifica brevemente** la respuesta.

   a) ¿Cuál es el objetivo principal del preprocesamiento de texto en la Recuperación de Información?

      a) Mejorar la calidad gramatical del texto
      b) Reducir el ruido y estandarizar los datos textuales
      c) Aumentar el tamaño del corpus
      d) Generar sinónimos de las palabras del texto

   b) ¿Por qué es importante el uso del esquema TF-IDF en el modelo de espacio vectorial para la Recuperación de Información?

      a) Para asegurar que los términos más frecuentes en todos los documentos tengan mayor relevancia en la consulta.
      b) Para ponderar los términos según su frecuencia en el documento y su rareza en el corpus.
      c) Para eliminar términos irrelevantes y reducir el tamaño del corpus.
      d) Para normalizar la longitud de los vectores de documentos y consultas.

   c) ¿Cuál de las siguientes afirmaciones sobre la tokenización es correcta?

      a) Divide el texto en sinónimos para simplificar el análisis
      b) Se utiliza para identificar palabras clave
      c) Fragmenta el texto en unidades más pequeñas, como palabras o frases
      d) Identifica el idioma a partir del texto de entrada

   d) ¿Qué son las *stop words* en el preprocesamiento de texto?

      a) Palabras que se traducen automáticamente durante el análisis
      b) Palabras que no aportan significado relevante
      c) Términos técnicos que requieren una atención especial en el análisis
      d) Errores gramaticales detectados en el texto

   e) ¿Cuáles de las siguientes afirmaciones reflejan correctamente la relación entre la Recuperación de Información (RI) y las Bases de Datos (BD)?

      a) Ambas tienen en cuenta el número de ocurrencias de los elementos para calcular la salida.
      b) Ambas utilizan índices para acelerar las búsquedas en grandes volúmenes de datos.

c) Los sistemas de BD suelen ser más adecuados para consultas que requieren precisión exacta, mientras que la RI tolera resultados aproximados basados en relevancia.

d) La RI y las BD utilizan las mismas métricas para evaluar el rendimiento, como la precisión y el recall.

f) ¿Qué mide el NDCG en la evaluación de sistemas de Recuperación de Información?

a) La proporción de documentos relevantes recuperados en comparación con el total de documentos relevantes.

b) La calidad de la ordenación de los documentos recuperados, priorizando los más relevantes en las primeras posiciones.

c) La cantidad total de documentos relevantes recuperados, frente a lo que sería la respuesta ideal del sistema.

d) El tiempo promedio que tarda el sistema en procesar una consulta.

g) Ante una determinada consulta, la única información que tenemos como indicio de calidad del sistema es el juicio de relevancia para los elementos recuperados. ¿Qué métricas podemos utilizar?

a) La precisión media

b) F1

c) Normalized Discounted Cumulative Gain

d) Precisión Interpolada.

2. (1.5 puntos) Un documento A tiene 20 ocurrencias del termino x y 3 ocurrencias del término y, mientras un documento B tiene 5 ocurrencias de x y 4 de y. Explica las razones por las que ante la consulta x, y se favorece que el documento B pueda aparecer antes que A en el ranking cuando consideramos BM25.

3. (1.5 puntos) Responda a las siguientes cuestiones sobre esta fórmula:

$$P(q|d) = \prod_{t \in q} P_{mle}(t|d) = \prod_{t \in q} \frac{tf_{t,d}}{\#words_d}$$

a) ¿A qué modelo de recuperación de información corresponde? ¿en qué se basa el modelo?

b) ¿Qué se está asumiendo al utilizar el operador $\prod$?

c) ¿Qué problema grave plantea esta fórmula en la práctica? ¿conoces alguna técnica para aliviar este problema?