Universidad de Granada
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL
ETSII Informática y de Telecomunicación, C/Periodista Daniel Saucedo Aranda s/n - 18071 - Granada (España)

Parcial 2: Tiempo 1 hora 30 min

4. (2 puntos) Para cada una de la siguientes cuestiones identifica cuál o cuales de de las respuestas ofrecidas puede puede ser cierta y para cada una de ellas **justifica brevemente** la respuesta.

   a) ¿Cuál de las siguientes afirmaciones sobre el uso de Skiplist en la indexación de Recuperación de Información es correcta?

      a) Las Skiplists permiten saltar posiciones en una lista invertida para acelerar la búsqueda de términos en documentos.
      b) Las Skiplists son una alternativa al uso de estructuras de acceso directo en la creación de índices.
      c) Su estructura se basa en dividir la lista invertida en bloques fijos de igual tamaño.
      d) Mejoran la eficiencia en consultas booleanas y de rango al evitar comparar innecesariamente todos los elementos de la lista invertida.

   b) ¿Qué características tiene la indexación basada en bloques en Recuperación de Información?

      a) Permite procesar documentos en bloques, facilitando la construcción de índices para grandes colecciones de datos.
      b) Reduce la memoria requerida al cargar listas invertidas completas en memoria.
      c) Organiza los documentos en bloques semánticos para facilitar el indexar los términos.
      d) Está diseñada exclusivamente para colecciones de datos distribuidas y no puede aplicarse en sistemas locales.

   c) ¿Qué ventajas ofrece la indexación distribuida en sistemas de Recuperación de Información?

      a) Mejora la escalabilidad al permitir que el índice se almacene y procese en varios servidores.
      b) Incrementa la tolerancia a fallos al replicar datos en múltiples nodos.
      c) Facilita la ordenación de documentos relevantes en consultas booleanas.
      d) Reduce la latencia al dividir las consultas entre varios nodos que procesan en paralelo.

   d) ¿Qué factores influyen en el cálculo del PageRank de una página web?

      a) El número total de enlaces entrantes (backlinks) que recibe la página.
      b) La calidad de las páginas que enlazan hacia ella.
      c) El contenido textual de la página.
      d) La cantidad de enlaces salientes que tiene la página que proporciona el enlace.

   e) ¿Cuáles son algunas de las limitaciones del algoritmo PageRank en la clasificación de páginas web?

      a) No tiene en cuenta la relevancia del contenido de la página al calcular su PageRank.

b) No puede distinguir entre enlaces naturales y enlaces manipulativos (como los obtenidos por intercambio de enlaces).

c) Solo funciona con enlaces internos dentro de un sitio web, no con enlaces entre diferentes sitios.

d) Requiere un análisis exhaustivo de las palabras clave de las páginas para calcular su relevancia.

f) ¿Cuál es el objetivo principal de LDA (Latent Dirichlet Allocation) en la modelización de temas en textos?

a) Identificar la probabilidad de que un documento pertenezca a una categoría predefinida.

b) Encontrar un conjunto de temas latentes que mejor describen la distribución de palabras en un corpus de documentos.

c) Asignar una etiqueta única a cada documento basado en el contenido textual.

d) Clasificar documentos según su similitud semántica utilizando redes neuronales profundas.

g) ¿Qué parámetros son fundamentales para el proceso de modelado en LDA?

a) El número de temas (K) a extraer del corpus.

b) La probabilidad de que una palabra pertenezca a un tema dado.

c) El tamaño del corpus utilizado para entrenar el modelo.

d) La probabilidad de que un documento contenga un tema específico.

5. (1.5 punto) ¿Cómo construirias un filtro de correo basura (spam)?. Pon un ejemplo teniendo en cuenta los documentos de la tabla, donde los documentos 5,6,7 y 8 son clasificados como spam

término	d1	d2	d3	d4	d5	d6	d7	d8
aaa	4	0	0	0	2	8	0	0
bbb	0	4	2	1	0	2	4	0
ccc	1	1	2	0	0	4	2	1
ddd	0	0	0	1	2	0	4	4
eee	0	1	4	0	0	0	4	4
fff	1	0	2	0	0	2	0	1
ggg	0	0	0	2	4	0	8	8

6. (1.5 punto) Define que representan los valores de Hub y Authority en el algoritmo HITS (Hypertext Induced Topic Selection). ¿Cómo se calculan?. Pon un ejemplo sobre el siguiente grafo donde se consideran 4 páginas webs A,B,C y D, donde A presenta hiperenlaces a B y C, B a C, D a C y C a A.